



## **Análise das séries temporais de cargas na rede de distribuição de energia de Alagoas para previsão de demanda utilizando regressões lineares e não-lineares**

**Cláudio Igor Fontes Medeiros<sup>1</sup>, Paulo Wagner Lopes da Silva<sup>2</sup>, André Ricardo Nunes Rocha<sup>3</sup>, Marcos Antônio Machado Dias<sup>4</sup>**

<sup>1</sup> Graduando do Instituto Federal de Alagoas – AL. e-mail: igor.fontes.m@gmail.com

<sup>2</sup> Professor do Instituto Federal de Alagoas - AL. e-mail: paulo.wagner@ifalpalmeira.edu.br

<sup>3</sup> Eletrobras Distribuição Alagoas. e-mail: andre@gmail.com

<sup>4</sup> Eletrobras Distribuição Alagoas. e-mail: marcos.machado@ceal.com.br

**Resumo:** A demanda de energia elétrica pode não ser suprida pelas concessionárias em alguns momentos, onde o consumo dos clientes é maior que a demanda de carga, assim faz-se necessário fazer previsões sobre os valores das demandas, para que a concessionária não compre energia em excesso nem em falta. Existem métodos simples de previsão que podem auxiliar os gestores na elaboração do Programa Mensal de Operação Energética, alguns destes métodos são apresentados neste trabalho, na forma de estudo de caso. Os modelos aqui analisados são os de regressões lineares e não lineares. Nesta pesquisa foram modeladas funções polinomiais aos valores de demanda medidos no ponto de instalação de um religador automático de uma subestação da Eletrobrás Distribuição Alagoas (Pilar) e a partir dos resultados observados foram tiradas conclusões acerca da eficiência dos polinômios modelados. O objetivo do trabalho é fazer previsões de demanda de energia elétrica em redes de distribuição com a utilização de métodos simples e fazer um comparativo de eficiência entre os métodos utilizados. Os resultados mostraram que com análise prévia da série temporal e aplicação de métodos simples de previsão é possível obter resultados satisfatórios para o planejamento.

**Palavras-chave:** análise, carga elétrica, regressão linear, previsão

### **Introdução**

A energia elétrica para ser consumida nas residências passa por diversos processos, ela é gerada em uma usina (geração), transportada por linhas de transmissão (transmissão) e entregue aos consumidores por redes de distribuição (distribuição), esse processo necessita de uma perfeita combinação, de modo que a transmissão produza a energia suficiente para atender todos os clientes sem excesso de produção.

A eletricidade desde sua descoberta até os dias atuais, vem se ampliando por todos os locais onde se possa imaginar. Hoje em dia podemos dizer que é impossível a sobrevivência financeira de uma cidade sem a utilização de energia elétrica. Pelas estatísticas do IBGE, nos centros urbanos a taxa de atendimento aos consumidores chega a 99%, enquanto na área rural atinge 77% [3]. Essa demanda de energia elétrica pode não ser suprida em alguns momentos, onde o consumo é maior que a demanda de carga.

A previsão é uma ferramenta bastante interessante, com uma boa análise a partir dos valores obtidos podemos tirar uma grande quantidade de informação para decisões de demanda de acordo com a necessidade e principalmente a prevenção, para que a demanda de carga não deixe de suprir a necessidade de toda a população. Um aspecto muito importante para a obtenção de bons resultados na previsão de carga é a verificação da dependência serial entre seus valores, pois quando o grau de previsibilidade para uma série é alto então a sua previsão também é boa [1]. É necessário prever com a exatidão adequada a quantidade de energia elétrica que o mercado irá consumir, até para que o sistema esteja sempre preparado para satisfazer as necessidades de consumo e nenhum consumidor fique prejudicado [4].

O objetivo desta pesquisa é fazer previsões de demandas de energia elétrica de médio prazo (mês) utilizando o banco de dados da Eletrobrás Distribuição Alagoas, estas informações foram analisadas através de regressões lineares e não lineares. O banco de dados foi organizado em períodos anuais, com os dados divididos mensalmente, devido à periodicidade dos dados. Com a utilização de diversos modelos de regressão foi analisado o que melhor se aplica às informações, obtendo assim as melhores previsões.

### **Metodologia**

O método usado para fazer as regressões lineares é conhecido como método dos mínimos quadrados, por ser de fácil entendimento e em larga escala o mais utilizado para fazer estudos usando esses tipos de modelos [5]. Para fazer a modelagem este método utiliza a otimização, minimização, dos quadrados dos erros da função ajustada, encontrando assim o melhor modelo científico, daí seu nome de métodos dos mínimos quadrados.



Em muitas situações conhece-se um conjunto de dados, distribuídos no tempo, obtidos experimentalmente ou de uma série histórica de dados e desejasse obter a expressão analítica que melhor represente esse conjunto de pontos. Neste tipo de problemas não existe a necessidade que a função ajustada passe exatamente por todos os pontos, mais sim que mostre a tendência da série.

Para encontrar a expressão do modelo linear deve-se considerar um conjunto de dados disposto no tempo e deseja-se ajustar uma função linear. A partir desta ideia é traçada uma reta no gráfico de dispersão do banco de dados, a fim de torná-la a mais próxima possível dos valores correspondentes dos números da série é calculado o quadrado de todos os erros (de cada ponto). Na equação do somatório destes erros é feito uma otimização encontrando os valores de intersecção e inclinação da reta [6].

A regressão linear por mínimos quadrados pode ser linearizada, não necessariamente sendo uma reta. Essa linearização pode ser encontrada assumindo que a função ajustada é uma função não-linear como, por exemplo: uma função polinomial, exponencial, logarítmica, potencial e hiperbólica. A metodologia para determinação destas funções é a mesma da linear, o que difere é a equação destas funções e suas especificações.

### Estudo de Caso – Subestação de Pilar

Na previsão de médio prazo da operação é elaborado o Programa Mensal de Operação Energética (PMO) onde são estabelecidas diretrizes energéticas para a operação coordenada e econômica do Sistema Interligado Nacional. O PMO é revisto semanalmente sempre que alterações nas premissas e/ou nas condições de operação acarretar em desvios significativos em relação aos resultados previstos [4]. A fim de auxiliar de forma significativa nas decisões inerentes a formulação do PMO a presente pesquisa destina-se a analisar as séries temporais através de métodos já conhecidos na literatura como regressões lineares e polinomiais.

Para realizar os estudos referentes a previsão foram coletados dados da Subestação de Pilar. Pilar é uma cidade alagoana com 33 mil habitantes, que esta situada a 36 km da capital Maceió. O município de Pilar é rico como as outras cidades da região pela a extração da cana de açúcar, além da pesca, onde Pilar é conhecida como a cidade do peixe bagre. A cidade também tem indústrias, grandes fazendas produtoras de alimentos e pecuárias. Pilar conta com uma subestação de energia elétrica própria, capaz de alimentar toda a cidade, região e ainda é responsável pelo controle e abastecimento elétrico da cidade de Marechal Deodoro, cidade litorânea do estado de Alagoas.

Escolhendo um equipamento para realizar o estudo inicial e posteriormente expandi-lo para todos os equipamentos da subestação que realizam medições. A ideia é ter percepção da tendência dos dados e, a partir deste conhecimento determinar dentre os métodos mais simples qual o melhor para cada situação.

A extrapolação de uma função só e viável se um banco de dados organizado estiver disponível para este fim, logo, o primeiro passo do trabalho foi coletar essas informações, esse banco de dados relaciona a demanda no ponto de instalação do religado na subestação com os respectivos meses. Os dados foram divididos por ano, devido a verificação de uma sazonalidade dos dados neste período.

Na análise, usando o *MS Excel*, foi feito o gráfico de dispersão e calculado as equações para as regressões lineares e algumas regressões polinomiais com graus variados, a fim de identificar se alguma se mostra eficiente na situação estudada. Na Tabela são apresentados alguns resultados.

O coeficiente de *Pearson* é uma medida numérica da força de relação entre as variáveis [6], ele varia de zero até a unidade e quanto maior, mais uma variável tem influência sobre a outra, outra forma de compreendê-lo é interpretá-lo como a eficiência do modelo ajustado, o certo é que quanto mais perto do valor 1, (independente do sinal for positivo ou negativo) maior é o grau de dependência estatística linear entre as variáveis, logo o aposto, quanto mais perto do 0 menor é a força dessa relação. O nome desse coeficiente é dado como homenagem a um de seus desenvolvedores, *Karl Pearson*.

O somatório dos mínimos quadrados é uma técnica geral, que se aplica para determinar parâmetros de uma relação funcional entre duas ou mais grandezas de um fenômeno ou valor mais provável de uma única grandeza medida varias vezes. O somatório dos mínimos quadrados pode indicar o erro da previsão, então, quanto mais próximo do zero ele encontra-se, melhor é o ajuste.

Tabela 1: Valores dos mínimos quadrados e dos coeficientes de *Pearson* para a reta de regressão e para a regressão polinomial do 2º grau.

Função Ajustada	Soma dos Mínimos Quadrados	Coeficiente de <i>Pearson</i>
Linear	0,463383551	0,0425
Polinomial do 2º grau	0,079697514	0,8355

A partir dos resultados obtidos (Tabela ) e da observação do gráfico de dispersão da Figura 1 é possível verificar que a função polinomial do segundo (2º) grau se ajusta melhor ao banco de dados, devido à semelhança do gráfico de dispersão com o formato do gráfico da função, essa tendência do banco de dados ocorre devido à influência de fator determinantes no consumo de energia elétrica, fatores estes que são externos ao sistema, como fatores climáticos e socioeconômicos, como é possível verificar nos meses de verão a demanda de energia elétrica no ponto de medição é bem maior que nos meses de inverno, isso ocorre devido ao excesso de consumo de aparelhos como condicionadores de ar durante os períodos quentes.




Figura 1: Gráfico de dispersão com o ajuste da reta de regressão e da função polinomial do 2º grau.

Com a utilização da regressão polinomial do 2º grau (regressão quadrática) os indicadores de eficiência apresentam valores bem melhores, a soma dos erros quadráticos teve uma redução de 0,46338 para, aproximadamente, 0,079697 o que representa uma melhora de 82,8% na previsão se comparado a reta de regressão. Este resultado é possível ser verificado, também, através da observação do coeficiente de *Pearson*, interpretando-o como medida da eficiência do método é possível verificar se comparado os dois modelos, que o coeficiente aumentou em torno de 82%.

A regressão quadrática mostra-se como um método de razoável precisão para a situação estudada (coeficiente acima de 0,8) [6], ele mostra a tendência das demandas durante o ano, o que possibilita, de maneira simples, a determinação de valores para elaboração do PMO.

A Figura 2 mostra um comparativo entre os valores dos coeficientes de *Pearson* das funções polinomiais ajustadas aos dados. Foram ajustados polinômios de diferentes graus (1 até 6) com o objetivo de compará-los e identificar qual dentre eles apresentava melhor resultado. A fim de, simplificar a visualização da comparação, foi gerado o gráfico de comparação (Figura 2).






Figura 2: Comparativo entre os valores do coeficientes de *Pearson*.

Verifica-se, através da observação da Figura 2, que o modelo com a melhor previsão é o polinômio de sexto (6º) grau, é importante analisar, quando da necessidade de fazer previsão, a precisão exigida, sabendo-se que quanto mais preciso o modelo mais complexo é sua modulação, assim em determinadas situações, métodos simples, como os apresentados neste trabalho, apresentam resultados satisfatórios.

### Conclusões

Apesar de sua relevância prática, técnicas quantitativas de previsão são desconhecidas, na quase totalidade, por um grande número de empresas. Este fato, embora expresse a realidade brasileira, não representa o que vem sendo feito em outros países, onde estas técnicas são bem difundidas, inclusive nos setores de serviços e de redes de utilidades públicas.

O estudo de casos, além de ilustrar a metodologia proposta, expôs as dificuldades de modelagem de dados reais, em vista da aleatoriedade dos dados. Neste artigo, buscou apresentar os principais métodos quantitativos de previsão de demanda conhecidos como modelos causais, relacionando sua eficiência em um estudo de caso.

Os resultados obtidos com a utilização das curvas de regressão são animadores devido ao grande aumento da eficiência em função do aumento do grau das curvas, com isso as expectativas com a utilização dos próximos métodos é que esses erros reduzam a um grau aceitável pelas empresas, e assim inserir sistemas de previsão de demanda bastante simples com uma boa precisão.

### Agradecimentos

Ao Instituto Federal do Campus de Palmeira dos Índios, pela aceitação do projeto;  
Aos professores e demais profissionais da área pela atenção e prestação de tempo a orientação;  
À Eletrobrás do estado de Alagoas, através de seus funcionários;  
À todos que assim como eu acreditaram no projeto do começo ao fim, incentivando e ajudando da melhor maneira possível.

### Literatura citada

- [1] DIAS, Marcos A. M. **Previsão de Carga no Curtíssimo Prazo com a Utilização de Redes Neurais Artificiais**. Maceió, AL; 2009. Dissertação de Mestrado apresentada a Universidade Federal de Alagoas.
- [2] DOURADO, Rosana Aparecida. **Formulação de um Modelo de Projeção de Demanda de Energia Elétrica Aplicado a Sistemas Isolados em Desenvolvimento Natural: O Caso da CERON**. Florianópolis, SC; 2004. Tese de Doutorado apresentada a Universidade Federal de Santa Catarina.
- [3] ELETROBRAS, **Plano decenal da expansão 2001-2010**. Rio de Janeiro, 2002.
- [4] DIAS, Marcos A. M. In: Mello, H.C.F. **Setor Brasileiro: Visão Política e Estratégica**. Monografia (Cursode Altos Estudos de Política e Estratégia) – Escola Superior de Guerra (ESG). Rio de Janeiro, 1999.
- [5] SILVA, Paulo Wagner de. **MODELOS MATEMATICOS PARA PREVISÕES E COMPARATIVOS DE EFECIÊNCIA USANDO O MAPPLE**. Arapiraca, AL; 2009. Artigo submetido ao IV CONNEPI.
- [6] TRIOLA, Mario F. **Correlacao e Regressao**. In: **Introducao a Estatística**. 10 ed. Rio de Janeiro: LTC, 2008. Cap 10, p. 408 – 465.